6 - Introduzione ai SO

Il sistema operativo deve rendere ***conveniente*** l'uso del calcolatore ai potenziali utenti, deve essere ***efficiente*** nell'utilizzo del calcolatore e delle sue parti costruttive e deve avere la ***capacità di evolversi*** rispetto alle sue evoluzioni hardware e delle esigenze degli utenti

Sistema operativo come interfaccia

L'obbiettivo principale di un sistema operativo è rendere ***trasparente*** all'utente la parte hardware che usa programmi applicativi

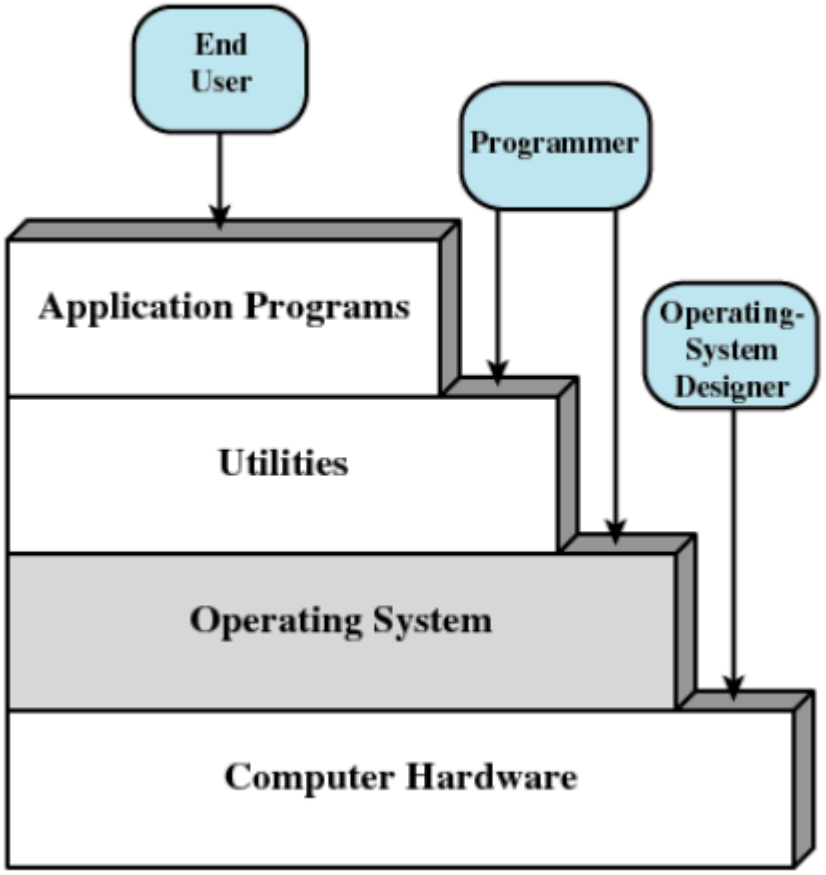

Servizi offerti dal SO

Il sistema operativo offre diversi servizi all'utente finale:

- **Creazione di programmi**: compilatore, debugger come utilità offerte al programmatore, non sono parte del SO ma sono accessibili tramite esso
- **Esecuzione di programmi**: caricamento in memoria dei programmi, inizializzazione dei dispositivi I/O etc.
- **Accesso ai dispositivi di I/O**: l'utente/programmatore non considera il set di istruzioni e i segnali dei dispositivi

- **Accesso controllato ai file**: comprendere i formati di file (pdf, word etc.), meccanismi di protezione e associazione dei file indirizzi di memoria
- **Accesso al sistema**
- **Rilevazione e correzione degli errori** hardware o generati dai programmi in esecuzione (come overflow)
- **Contabilità e statistiche d'uso delle risorse e dei tempi di risposta** (al fine di migliorare le prestazioni)

SO come gestore delle risorse (efficienza del SO)

Il sistema operativo è fatto di istruzioni, contenuto in memoria RAM nel suo principio, nel tempo però ci si è resi conto che alcune parti del sistema operativo vengono invocate molto raramente o meno frequentemente;
Definiamo **kernel** (al momento) come parte del sistema operativo residente in memoria centrale che contiene le funzioni usate più di frequente
Il sistema operativo:

- Dirige la CPU nell'utilizzo delle altre risorse del sistema e nella temporizzazione delle esecuzione dei programmi
- Decide quando un programma in esecuzione può usare una risorsa (persino il processore)

Batch multi programmati

Prima esisteva la mono programmazione, cioè la possibilità di eseguire un unico programma sul calcolatore (ipotizzando sia single core)

Lettura di un record	0.0015 sec.
Esecuzione di 100 istruzioni	0.0001 sec.
Scrittura di un record	0.0015 sec.
TOTALE	0.0031 sec.

Percentuale di utilizzo CPU

$$= \frac{0.0001}{0.0031} = 0.032 = 3.2\%$$

Poi è nata la multi programmazione, dove sono presenti più programmi in memoria e il suo obbiettivo è limitare l'inattività del processore, quando un job effettua un operazione di I/O la CPU può essere impegnata da un altro processo, in modo da non farla fermare mai.
Il singolo core di prima viene sfruttato in più modi.

Multi-tasking

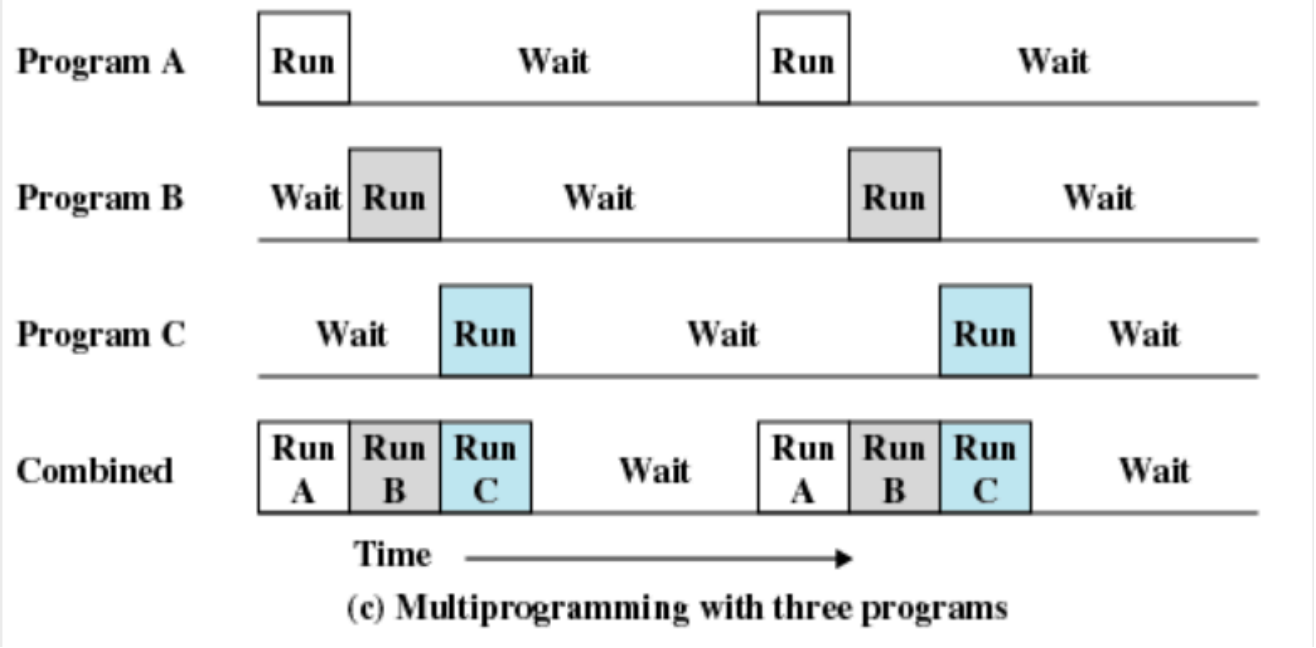

Il multi-tasking è l'estensione logica della multi programmazione, la CPU esegue più lavori commutando le loro esecuzioni con una frequenza tale da permettere a ciascun utente di usufruire di tempi di risposta rapidi. Normalmente un processo, durante la sua esecuzione, impegna la CPU per un breve periodo di tempo prima di terminare o richiedere delle operazioni di I/O;
Tali operazioni possono essere interattive (come l'inserimento a tastiera) ma durante questa operazione interattiva il sistema commuta rapidamente la CPU ad un altro processo

Mono programmazione vs Multi programmazione

Con la *mono-programmazione* può essere mandato in esecuzione solamente un processo per volta rendendo inutilizzata la CPU nel caso in cui il processo stia effettuando operazioni di I/O (acquisizione da tastiera, condivisione di dati in **uscita** verso una stampante ecc...). Il tempo e la percentuale di utilizzo della CPU con questo modello risultano molto elevati.

Formula che calcola la percentuale di utilizzo della CPU :
TO = tempo totale operazioni(sec.)
TI = tempo esecuzione di *n* istruzioni (sec.)

$$\frac{TO}{TI}$$

Attraverso la *multi-programmazione* si possono mandare in esecuzione più processi per volta in base alle caratteristiche hardware della CPU (numero di core). L'obiettivo principale è quello di limitare l'inattività del processore quando un processo effettua un'operazione di I/O impegnandolo con un altro processo, questo farà si che sia possibile elaborare i task in maniera seriale. Ci sono delle difficoltà che si presentano con la multiprogrammazione, quest'ultimi riguardano la ***gestione della memoria*** e delle risorse disponibili poiché potranno essere usate da tutti i processi anche in più istanti diversi ed infine è necessario anche un algoritmo che decida quale **job** mandare in esecuzione (*schedulazione*)

Processo = Job = Task

Ma cos'è un processo?
Partiamo in ordine:

- **Programma**: serie di istruzioni che operano sui dati
- **Dati**: alcuni sono immediatamente noti (come le variabili), altri sono noti a runtime (o ad esecuzione)
  Un processo è un **programma in esecuzione** che deve essere portato in memoria RAM, capendo quale risorse usa (tra cui la CPU).
  Il processo ha il proprio **contesto di esecuzione**, informazioni necessarie al sistema operativo per gestire il processo come:
- Contenuto dei registri della CPU
- Priorità
- Stato di esecuzione
- Stato di attesa su un dispositivo di I/O

Implementazione di un processo

Ogni processo è dunque formato da una struttura contenente una serie di componenti (programma, dati, contesto), quest'ultimo per essere eseguito deve essere caricato in RAM, considerando un sistema multi-programmato, tipico dei calcolatori moderni, è possibile che in memoria siano caricati altri processi pronti per essere eseguiti o già in esecuzione.
Nell'istante in cui un processo viene mandato in esecuzione all'interno dei registri della CPU (che sono di numero limitato) devono essere trasferiti tutti i dati necessari al processo che sta per essere eseguito per funzionare, tra questi possiamo trovare:

- PC che punta all'istruzione successiva del processo da eseguire
- L'indice del processo all'interno della *lista dei processi*
- Registri che contengono l'indirizzo *Base* e *Limite* necessari per proteggere le aree di memoria degli altri processi, quest'ultimi infatti indicano il primo e l'ultimo indirizzo delle celle (tutte contigue) di memoria in cui è contenuto il processo

Questi dati sono definiti come il contesto di un processo e consentono anche di riprendere l'esecuzione di un processo che è stato sostituito da un altro da dove si era fermato.
L'operazione di passaggio da un processo ad un altro è chiamata **context switching** e i passaggi principali che deve eseguire sono:

1. Salvataggio del primo contesto
2. Caricamento del secondo

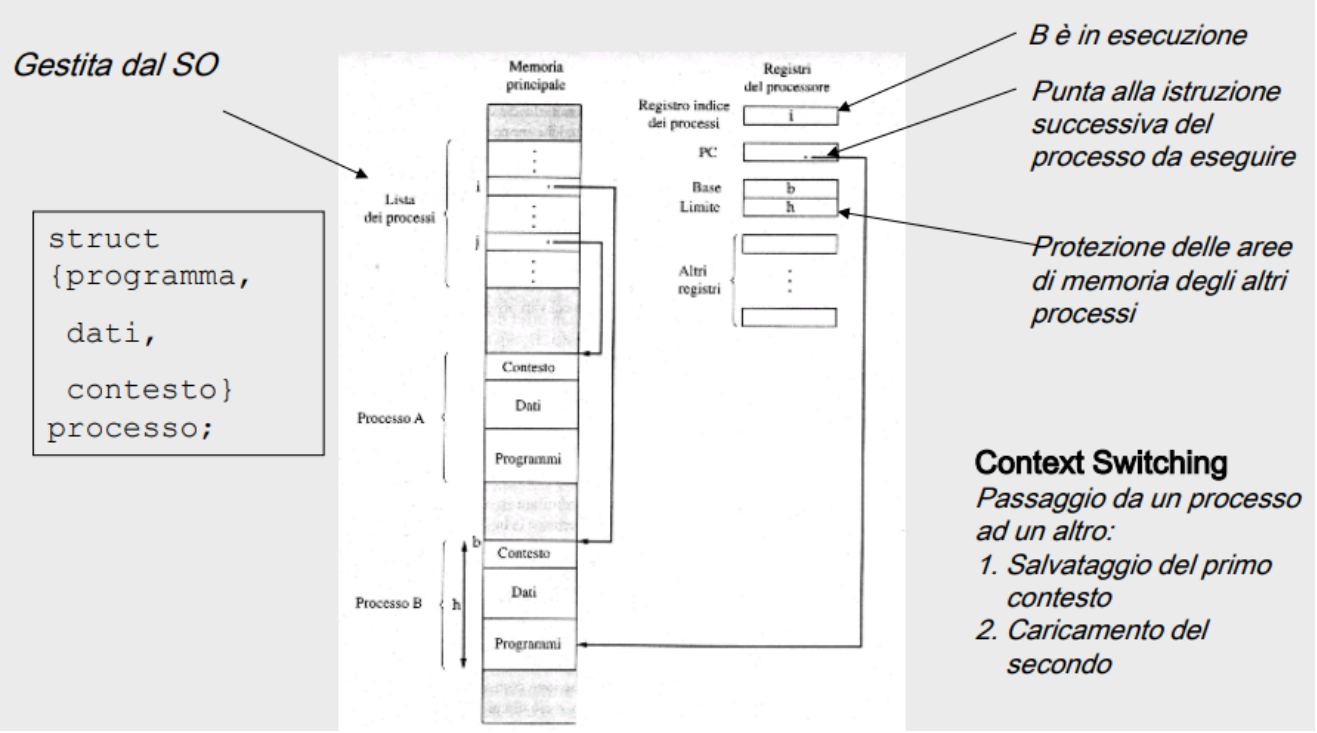

Gestione della memoria

Il sistema operativo deve assolvere 5 compiti per le memorie:

- **Isolamento dei processi**: i programmi non si interfacciano tra di loro nella memoria centrale, hanno il loro spazio riservato
- **Allocazione e gestione automatica della memoria**: la gerarchia delle memorie deve essere trasparente all'utente
- **Supporto alla programmazione modulare**: in un programma si porta unicamente il main e le funzioni vengono chiamate dinamicamente, caricandole quando se ne ha bisogno. La parte modulare di un programma non ha mai una dimensione variabile ma un processo sì
- **Protezione e controllo dell'acceso**: gestione di aree di memoria condivise tra i processi
- **Memorizzazione a lungo termine**: il file system in breve

Alcune necessità sono soddisfatte da:

- **Memoria virtuale (memoria RAM + parte di Hard Disk)**: i programmi indirizzano la memoria con riferimenti logici ignorando gli aspetti fisici, quando un programma è in esecuzione solo una sua parte risiede effettivamente in memoria centrale. In modo semplice, è il modo in cui il sistema operativo permette di poter far eseguire processi che occupano più memoria di quella presente fisicamente nel sistema (sempre nei limiti possibili).
- **File system**: implementa la memorizzazione a lungo termine

Schedulazione

La schedulazione è la definizione di un ordine con cui i processi devono essere eseguiti.
La politica di allocazione delle risorse deve considerare i seguenti fattori:

- **Equità**: tutti i processi appartenenti ad una stessa classe, o con richieste simili, o stesso costo, devono avere la stessa possibilità di accesso alla risorsa
- **Tempo di risposta differenziale**: il sistema operativo discrimina tra classi che hanno bisogno di risorse diverse e tempi diversi (come i processi con forte uso di I/O vengono schedulati per primi)
- **Efficienza**: massimizzare il throughput, minimizzare il tempo di risposta