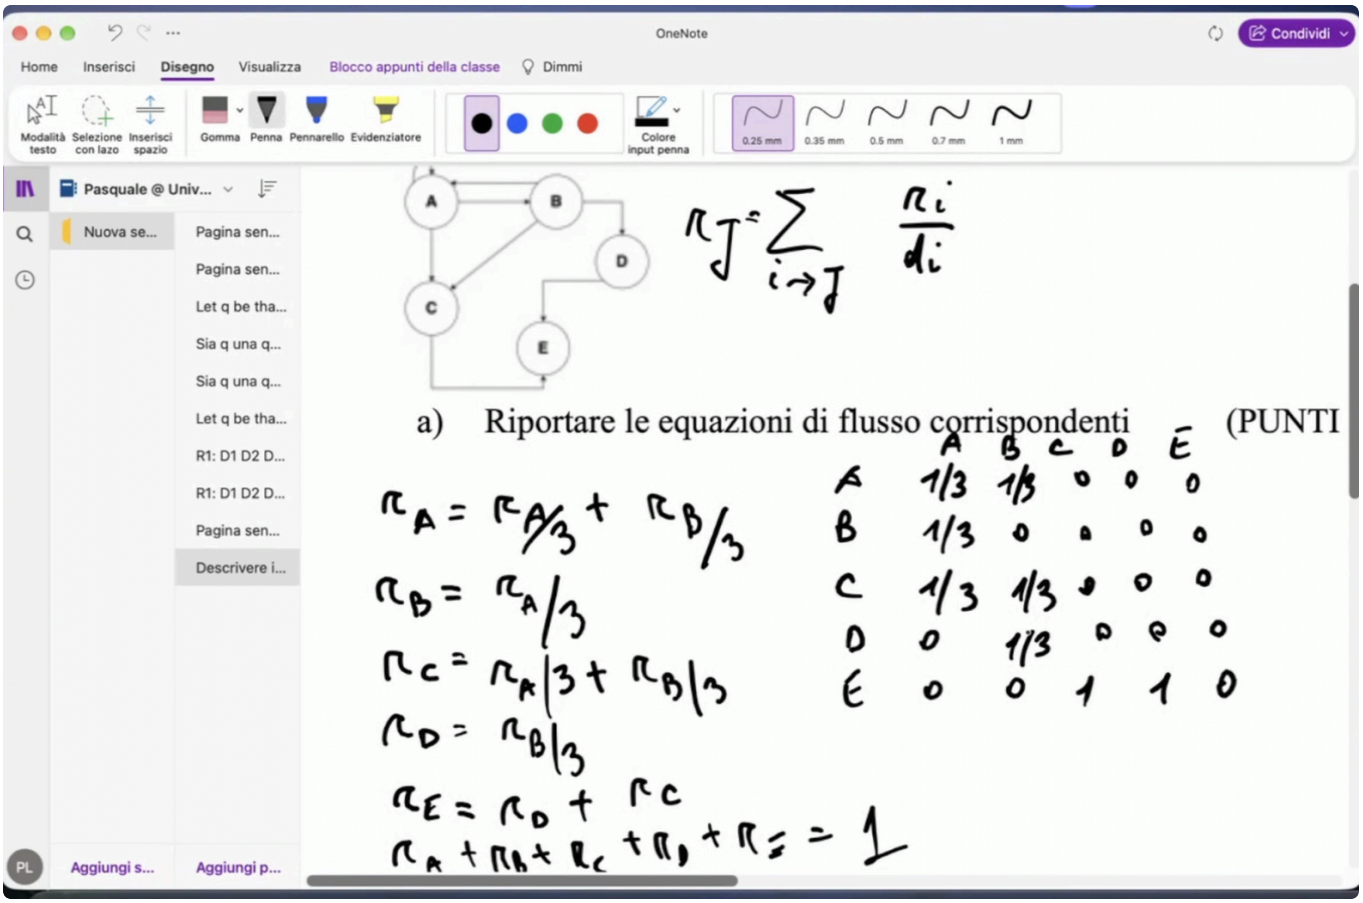
1) Descrivere in maniera sintetica i principi alla base del PageRank, focalizzando l'attenzione sulla formulazione basata sulle *equazioni di flusso*. (PUNTI 7)
Partendo dal seguente grafo:



a) Riportare le equazioni di flusso corrispondenti (PUNTI 3)



Descrizione sintetica dei principi del PageRank e delle Equazioni di Flusso

L'algoritmo **PageRank** nasce per misurare l'importanza delle pagine all'interno del Web, modellato come un **grafo orientato** in cui i **nodi** sono le pagine web e gli **archi orientati** sono i collegamenti ipertestuali.

Il principio cardine del PageRank consiste nell'interpretare i **link come dei voti**:

- Se un nodo riceve molti link in ingresso da altre pagine, significa che molte pagine lo "votano" e quindi è considerato un nodo di una certa importanza.

- I link provenienti da pagine a loro volta importanti valgono di più. Di conseguenza, anche se un nodo possiede **pochi link in ingresso** (o persino un solo link, risultando quasi isolato), se quel collegamento proviene da un nodo molto importante, anche il nodo poco connesso acquisisce per riflesso una notevole importanza.
- L'importanza che una pagina sorgente i trasferisce alle pagine che punta viene divisa equamente tra tutti i suoi d_i link uscenti (*out-links*).

Poiché l'importanza di una pagina dipende dall'importanza delle pagine che la puntano, il problema ha una natura **ricorsiva**. Nella **formulazione basata sulle equazioni di flusso**, il punteggio di PageRank r_j di un generico nodo j è definito come la somma dei voti portati dai suoi link entranti:

$$r_j = \sum_{i \to j} \frac{r_i}{d_i}$$

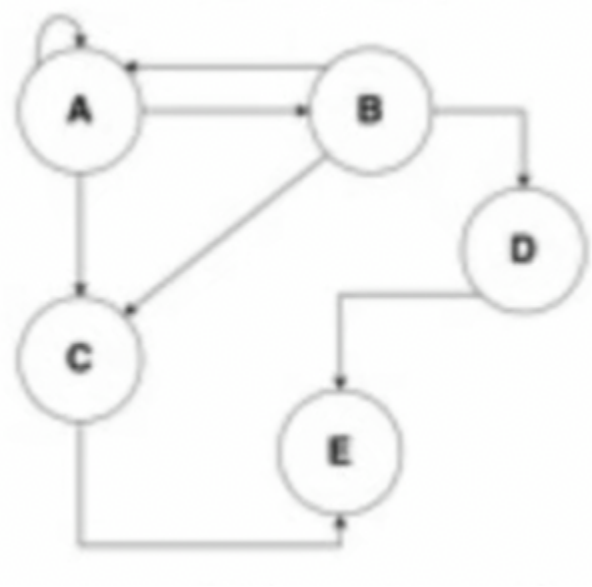
dove:

- $i \to j$ indica tutti i nodi i che hanno un arco orientato che entra nel nodo j.
- r_i è il punteggio di importanza (rank) del nodo sorgente i.
- d_i è il **grado uscente** (*out-degree*) del nodo i, ovvero il numero totale di archi che escono da i.

Poiché questo sistema di equazioni lineari è omogeneo (privo di termini noti costanti), ammette infinite soluzioni proporzionali tra loro. Per garantire l'**unicità della soluzione**, si aggiunge sempre il vincolo di normalizzazione secondo cui la somma dei rank di tutti gli N nodi del grafo deve essere uguale a 1:

$$\sum_{j=1}^{N} r_j = 1$$

Codifica delle Equazioni di Flusso del Grafo

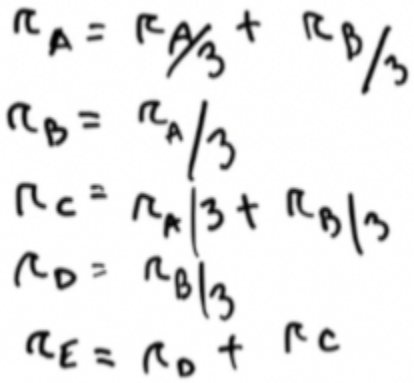


Analizziamo il grafo notiamo che:

- Il diagramma è composto da 5 **nodi** (A, B, C, D, E).
- Avremo quindi un sistema formato da 5 **equazioni di flusso** (una per ciascun nodo) $+1$ **equazione aggiuntiva** data dalla condizione di unicità (la somma di tutti i rank pari a 1), per un totale di 6 equazioni.

Prima di scrivere le equazioni, osserviamo quanti archi **escono** da ciascun nodo (questo numero andrà al denominatore):

- **Nodo** A **(**$d_A = 3$**):** ha 3 **link uscenti** $\rightarrow$ uno punta a se stesso ($A \rightarrow A$), uno va verso B ($A \rightarrow B$) e uno va verso C ($A \rightarrow C$). Ogni link uscente da A trasporta quindi un flusso pari a $\frac{r_A}{3}$
- **Nodo** B **(**$d_B = 3$**):** ha 3 **link uscenti** $\rightarrow$ uno va verso A ($B \rightarrow A$), uno va verso C ($B \rightarrow C$) e uno va verso D ($B \rightarrow D$). Ogni link uscente da B trasporta quindi un flusso pari a $\frac{r_B}{3}$.
- **Nodo** C **(**$d_C = 1$**):** ha 1 **solo link uscente** $\rightarrow$ va verso E ($C \rightarrow E$). Trasporta quindi tutto il suo peso $\frac{r_C}{1} = r_C$.
- **Nodo** D **(**$d_D = 1$**):** ha 1 **solo link uscente** $\rightarrow$ va verso E ($D \rightarrow E$). Trasporta quindi tutto il suo peso $\frac{r_D}{1} = r_D$.
- **Nodo** E **(**$d_E = 0$**):** ha 0 **link uscenti** $\rightarrow$ riceve frecce ma non ne fa partire nessuna.



Per scrivere l'equazione di ciascun nodo, dobbiamo guardare in ordine **quali sono le pagine (frecce) che entrano** in quel nodo:

1. **Equazione per r_A:** Guardiamo chi punta ad A: in A entrano la freccia proveniente da A **stesso** (che ha 3 uscite) e la freccia proveniente da B (che ha 3 uscite). Sommando i due contributi otteniamo:

$$r_A = \frac{r_A}{3} + \frac{r_B}{3}$$

2. **Equazione per r_B:** Guardiamo chi punta a B: l'unica freccia che entra in B proviene da A (che ha 3 uscite). Quindi:

$$r_B = \frac{r_A}{3}$$

3. **Equazione per r_C:** Guardiamo chi punta a C: nel nodo C entrano due frecce, una proveniente da A (che ha 3 uscite) e una proveniente da B (che ha 3 uscite). Quindi:

$$r_C = \frac{r_A}{3} + \frac{r_B}{3}$$

4. **Equazione per r_D:** Guardiamo chi punta a D: nel nodo D entra una sola freccia proveniente da B (che ha 3 uscite). Quindi:

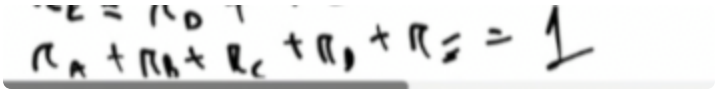
$$r_D = \frac{r_B}{3}$$

5. **Equazione per r_E:** Guardiamo chi punta a E: nel nodo E entrano due frecce, una proveniente da D (che ha 1 sola uscita, quindi $\frac{r_D}{1}$) e una proveniente da C (che ha 1 sola uscita, quindi $\frac{r_C}{1}$). Quindi:

$$r_E = r_D + r_C$$

6. **Condizione di unicità (normalizzazione):** Infine, imponiamo che la somma di tutti i 5 rank sia uguale a 1:

$$r_A + r_B + r_C + r_D + r_E = 1$$



Sistema completo delle Equazioni di Flusso (Risposta al punto a)

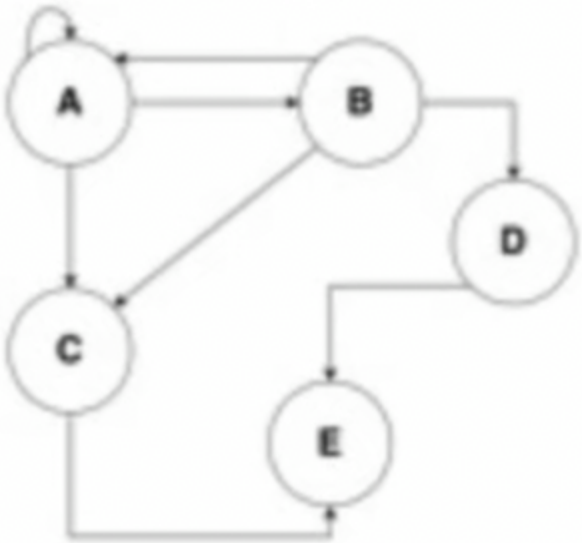
Raccogliendo tutte le equazioni trovate, la soluzione completa da riportare nell'esercizio è:

$$> \begin{cases} > r_A = \frac{r_A}{3} + \frac{r_B}{3} \\ > r_B = \frac{r_A}{3} \\ > r_C = \frac{r_A}{3} + \frac{r_B}{3} \\ > r_D = \frac{r_B}{3} \\ > r_E = r_D + r_C \\ > r_A + r_B + r_C + r_D + r_E = 1 > \end{cases} >$$

Costruzione della Matrice M, Dead End e Teleport (Matrice di Google A)

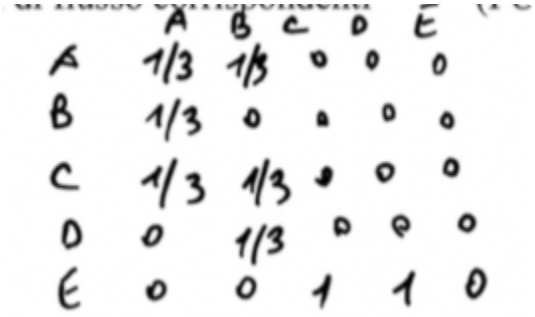
Costruzione della matrice di adiacenza M

Traduciamo ora il grafo e le equazioni di flusso nella matrice di adiacenza M di dimensione 5×5, disponendo sulle **colonne** i nodi di partenza (A, B, C, D, E) e sulle **righe** i nodi di arrivo (A, B, C, D, E):



- **Colonna A:** A punta ad A, B, C con peso $\frac{1}{3}$ ciascuno (e 0 verso D, E).
- **Colonna B:** B punta ad A, C, D con peso $\frac{1}{3}$ ciascuno (e 0 verso B, E).
- **Colonna C:** C punta solo ad E con peso 1 (e 0 altrove).
- **Colonna D:** D punta solo ad E con peso 1 (e 0 altrove).

- **Colonna E:** poiché da E non parte alcun link, **tutta la colonna E vale** 0.



Arrivo \ Partenza	A	B	C	D	E
A	$1/3$	$1/3$	0	0	0
B	$1/3$	0	0	0	0
C	$1/3$	$1/3$	0	0	0
D	0	$1/3$	0	0	0
E	0	0	1	1	0

La matrice M è stocastica?

Osservando la matrice appena costruita, chiediamoci: **possiamo dire che questa matrice è stocastica per colonne?**

- La risposta è **NO**!
- **Perché?** Affinché una matrice sia stocastica per colonne, la somma degli elementi di **ogni** singola colonna deve fare esattamente 1. Mentre le prime quattro colonne (A, B, C, D) sommano correttamente a 1, **l'ultima colonna (E) è composta interamente da zeri e la sua somma fa** 0 (indicata dalla freccia nell'immagine del professore).
- Dal punto di vista del grafo, questo accade perché **il nodo E è un *Dead End* (vicolo cieco)**: nel momento in cui il navigatore casuale entra nel nodo E, non ha più alcun link uscente e **non può più uscire da quel nodo**. Se applicassimo il metodo delle potenze a questa matrice così com'è, tutta l'importanza del grafo finirebbe per disperdersi attraverso E facendo convergere i rank a zero.

Trasformazione nella Matrice di Google A tramite il Teleport

Per risolvere il problema e permettere al navigatore di uscire da qualsiasi nodo o trappola, applichiamo la formulazione di Google introducendo il meccanismo del **Random Teleport** (salto casuale), definito dalla formula della **Matrice di Google** A:

$$A = \beta M + (1 - \beta)\frac{1}{N} e \cdot e^T$$

(Nota: in presenza del dead-end E, per avere una matrice perfettamente stocastica, nella colonna E di M si può sostituire la colonna di zeri con $\frac{1}{5}$ su tutte le righe, cioè teletrasporto con probabilità 1.0 dal dead-end, oppure scrivere direttamente la combinazione lineare.

Scegliendo ad esempio $\beta = 0.8$ (da cui $1 - \beta = 0.2$) e sapendo che i nodi sono $N = 5$ (quindi la probabilità di atterrare su un nodo qualsiasi con un salto casuale è $\frac{1}{N} = \frac{1}{5}$), la nuova matrice A impostata dal professore si scrive come:

$$A = 0.8 \begin{pmatrix} 1/3 & 1/3 & 0 & 0 & 0 \\ 1/3 & 0 & 0 & 0 & 0 \\ 1/3 & 1/3 & 0 & 0 & 0 \\ 0 & 1/3 & 0 & 0 & 0 \\ 0 & 0 & 1 & 1 & 0 \end{pmatrix} + 0.2 \begin{pmatrix} 1/5 & 1/5 & 1/5 & 1/5 & 1/5 \\ 1/5 & 1/5 & 1/5 & 1/5 & 1/5 \\ 1/5 & 1/5 & 1/5 & 1/5 & 1/5 \\ 1/5 & 1/5 & 1/5 & 1/5 & 1/5 \\ 1/5 & 1/5 & 1/5 & 1/5 & 1/5 \end{pmatrix}$$

⚠ Significato finale della nuova Matrice A

Sommando queste due matrici, otteniamo una nuova matrice A con caratteristiche fondamentali:

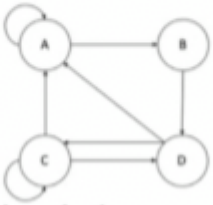
1. **Nessuno zero e grafo completamente connesso:** poiché nella seconda matrice tutte le celle valgono $\frac{1}{5}$ (moltiplicato per 0.2), nella matrice risultante A **non ci sarà più alcuno zero**. Dal punto di vista topologico, questo equivale a trasformare il grafo in un **grafo completamente connesso** (irriducibile e aperiodico), dove da ogni singolo nodo (incluso E) è sempre possibile raggiungere qualunque altro nodo.
2. **Bilanciamento tra navigazione via link e salto casuale:** la formula codifica esattamente il comportamento del navigatore sul Web: per circa l'**80% (o 90%) delle volte** ($\beta = 0.8$ o $\beta = 0.9$) si dà peso alla normale **navigazione attraverso il meccanismo dei link** del grafo, mentre per il restante **20% (o 10%) delle volte** ($1 - \beta = 0.2$ o 0.1) si effettua un **salto casuale (*teleport*)** verso una qualsiasi delle 5 pagine del grafo con probabilità uniforme pari a $\frac{1}{5}$.

Vuoi che calcoliamo anche i valori numerici finali dentro ogni singola cella della matrice A risultante, oppure passiamo a un altro esercizio?

---

2) Descrivere in maniera sintetica i principi alla base del PageRank, focalizzando l'attenzione sulla formulazione basata sulle equazioni di flusso (PUNTI 7)

a) Partendo dal seguente grafo:



L'algoritmo **PageRank** valuta l'importanza e l'autorevolezza delle pagine all'interno del Web, modellato matematicamente come un **grafo orientato** in cui i **nodi** rappresentano le pagine web e gli **archi orientati** rappresentano i collegamenti ipertestuali (*hyperlink*).

Il principio fondamentale del PageRank consiste nell'interpretare i **link come dei voti** (*Links as votes*):

- **Importanza basata sui link in ingresso (*in-links*):** una pagina è considerata tanto più importante quanto maggiore è il numero di link in ingresso che riceve dalle altre pagine del grafo.
- **Pesi differenti dei voti (natura ricorsiva):** i link in ingresso non hanno tutti lo stesso peso, poiché i voti provenienti da pagine a loro volta importanti contano di più. Di conseguenza, se un nodo ha molti link entranti acquista una certa importanza, ma anche un nodo con pochi link (o quasi isolato), se riceve un link da un nodo molto importante, ottiene per riflesso una notevole importanza.
- **Ripartizione equa del voto in uscita:** se una pagina i con importanza r_i possiede d_i link uscenti (*out-links*), essa ripartisce equamente il proprio voto tra tutte le pagine a cui punta, trasferendo a ciascun link uscente una quota pari a $\frac{r_i}{d_i}$.

Nella **formulazione basata sulle equazioni di flusso** (*Flow Formulation*), l'importanza complessiva (rank) r_j di un generico nodo j è data dalla somma dei voti trasportati da tutti i suoi link in ingresso:

$$r_j = \sum_{i \to j} \frac{r_i}{d_i}$$

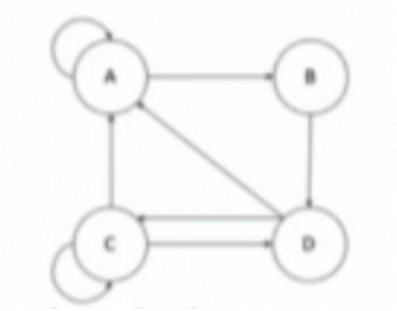
dove:

- $i \to j$ rappresenta l'insieme di tutti i nodi i che hanno un arco orientato entrante nel nodo j.
- r_i è il punteggio di PageRank della pagina sorgente i.
- d_i è il **grado uscente** (*out-degree*) del nodo i, cioè il numero totale di link che escono da i.

Poiché il sistema lineare formato dalle sole equazioni di flusso è privo di termini noti costanti e non ammette un'unica soluzione (tutte le soluzioni sono equivalenti a meno di un fattore di scala), si aggiunge il **vincolo di unicità (normalizzazione)** imponendo che la somma dei rank

di tutti gli N nodi del grafo sia pari a 1:

$$\sum_{j=1}^{N} r_j = 1$$



Analizziamo il grafo orientato fornito nella traccia dell'esercizio:

- Il diagramma è composto da $N = 4$ **nodi** (A, B, C, D).
- Avremo quindi un sistema composto da 4 **equazioni di flusso** (una per ciascun nodo) $+1$ **equazione aggiuntiva** data dalla condizione di unicità (la somma di tutti i rank pari a 1).

Osserviamo innanzitutto quante frecce **escono** da ogni singolo nodo (valore che andrà al denominatore):

- **Nodo A ($d_A = 2$):** ha 2 **link uscenti** $\rightarrow$ uno punta a se stesso tramite la freccia in alto a sinistra ($A \rightarrow A$) e uno va verso destra nel nodo B ($A \rightarrow B$). Ogni link che esce da A trasporta quindi un flusso pari a $\frac{r_A}{2}$.
- **Nodo B ($d_B = 1$):** ha 1 **solo link uscente** $\rightarrow$ la freccia verticale che scende verso il nodo D ($B \rightarrow D$). Trasporta quindi l'intero peso $\frac{r_B}{1} = r_B$.
- **Nodo C ($d_C = 3$):** ha 3 **link uscenti** $\rightarrow$ uno punta a se stesso tramite il cappio in basso a sinistra ($C \rightarrow C$), uno sale verticalmente verso il nodo A ($C \rightarrow A$) e uno va orizzontalmente a destra (la freccia inferiore) verso il nodo D ($C \rightarrow D$). Ogni link che esce da C trasporta quindi un flusso pari a $\frac{r_C}{3}$.
- **Nodo D ($d_D = 2$):** ha 2 **link uscenti** $\rightarrow$ la freccia diagonale che sale verso il nodo A ($D \rightarrow A$) e la freccia orizzontale superiore che torna a sinistra verso il nodo C ($D \rightarrow C$). Ogni link che esce da D trasporta quindi un flusso pari a $\frac{r_D}{2}$.

Per ricavare l'equazione di ogni nodo, controlliamo in ordine **quali sono le pagine che puntano a quel nodo** (frecce entranti):

1. **Equazione per r_A:** Le frecce che entrano nel nodo A sono 3: la freccia proveniente da A **stesso** (che ha 2 uscite), la freccia verticale che sale da C (che ha 3 uscite) e la freccia diagonale che sale da D (che ha 2 uscite). Sommando i contributi:

$$r_A = \frac{r_A}{2} + \frac{r_C}{3} + \frac{r_D}{2}$$

2. **Equazione per r_B:** Nel nodo B entra una sola freccia, quella orizzontale proveniente da A (che ha 2 uscite). Quindi:

$$r_B = \frac{r_A}{2}$$

3. **Equazione per r_C:** Le frecce che entrano nel nodo C sono 2: il cappio in basso proveniente da C **stesso** (che ha 3 uscite) e la freccia orizzontale superiore che proviene da D (che ha 2 uscite). Quindi:

$$r_C = \frac{r_C}{3} + \frac{r_D}{2}$$

4. **Equazione per r_D:** Le frecce che entrano nel nodo D sono 2: la freccia verticale che scende da B (che ha 1 sola uscita, quindi $\frac{r_B}{1} = r_B$) e la freccia orizzontale inferiore che proviene da C (che ha 3 uscite). Quindi:

$$r_D = r_B + \frac{r_C}{3}$$

5. **Condizione di unicità (normalizzazione):** Aggiungiamo infine il vincolo che la somma dei rank di tutti e 4 i nodi sia uguale a 1:

$$r_A + r_B + r_C + r_D = 1$$

Sistema completo delle Equazioni di Flusso (Risposta al punto a) Il sistema completo delle equazioni di flusso corrispondenti al grafo è:

$$> \begin{cases} > r_A = \frac{r_A}{2} + \frac{r_C}{3} + \frac{r_D}{2} \\ > r_B = \frac{r_A}{2} \\ > r_C = \frac{r_C}{3} + \frac{r_D}{2} \\ > r_D = r_B + \frac{r_C}{3} \\ > r_A + r_B + r_C + r_D = 1 > \end{cases} >$$

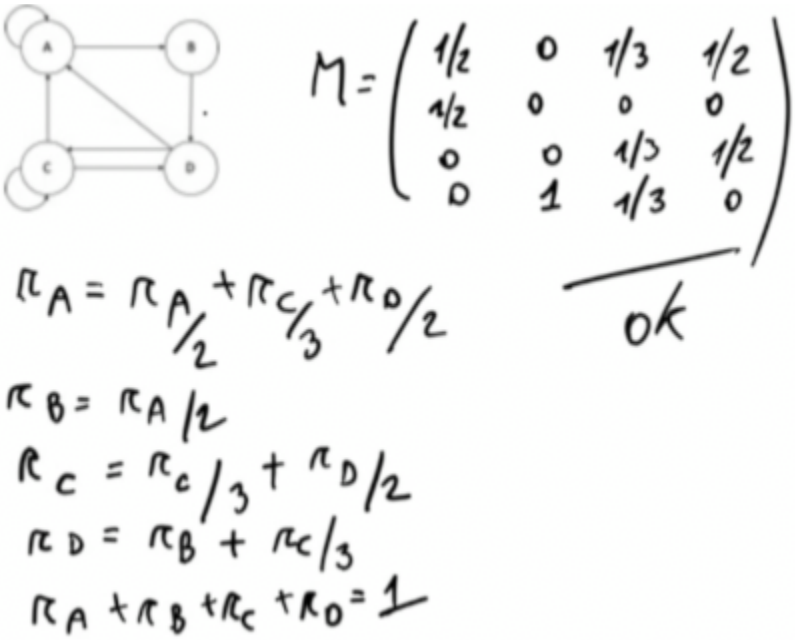
(Se volessimo anche risolverlo per sostituzione: dalla terza equazione $\frac{2}{3}r_C = \frac{1}{2}r_D \Rightarrow r_D = \frac{4}{3}r_C$; sostituendo nella quarta otteniamo $r_B = r_C$, e dalla seconda $r_A = 2r_C$. Imponendo $2r_C + r_C + r_C + \frac{4}{3}r_C = 1 \Rightarrow \frac{16}{3}r_C = 1$, troviamo i PageRank esatti: $r_A = \frac{6}{16}$, $r_B = \frac{3}{16}$, $r_C = \frac{3}{16}$, $r_D = \frac{4}{16}$).

Costruzione della matrice di adiacenza M

Codifichiamo ora il grafo nella matrice di adiacenza M di dimensione 4×4, mettendo sulle **colonne** i nodi di partenza (A, B, C, D) e sulle **righe** i nodi di arrivo (A, B, C, D):

- **Colonna A ($d_A = 2$):** punta ad A e B con valore $\frac{1}{2}$, e 0 verso C e D.
- **Colonna B ($d_B = 1$):** punta solo a D con valore 1, e 0 verso A, B, C.
- **Colonna C ($d_C = 3$):** punta ad A, C, D con valore $\frac{1}{3}$, e 0 verso B.
- **Colonna D ($d_D = 2$):** punta ad A e C con valore $\frac{1}{2}$, e 0 verso B e D.

Arrivo \ Partenza	A	B	C	D
A	$1/2$	0	$1/3$	$1/2$
B	$1/2$	0	0	0
C	0	0	$1/3$	$1/2$
D	0	1	$1/3$	0



La matrice M è stocastica?

Chiediamoci ora: **questa matrice M è stocastica per colonne?**

- A differenza dell'esercizio precedente, in questo caso la risposta è **SÌ, la matrice M è già stocastica per colonne**!
- **Perché?** Nel grafo **non sono presenti *Dead Ends* (vicoli ciechi)**: da qualunque nodo (A, B, C, D) parte sempre almeno un link uscente, quindi nessuna colonna è composta da

soli zeri e **la somma degli elementi di ciascuna colonna fa sempre esattamente** 1 ($\frac{1}{2} + \frac{1}{2} = 1$; $1 = 1$; $\frac{1}{3} + \frac{1}{3} + \frac{1}{3} = 1$; $\frac{1}{2} + \frac{1}{2} = 1$).

Applicazione del Random Teleport (Matrice di Google A)

Anche se non ci sono *dead-ends*, per garantire in generale che sul grafo non ci siano *spider traps* e per modellare la possibilità del navigatore di saltare da una pagina all'altra, possiamo comunque scrivere la **Matrice di Google** A applicando il **Random Teleport** con $\beta = 0.8$ ($1 - \beta = 0.2$) e $N = 4$ nodi (per cui la matrice di teletrasporto ha in tutte le celle il valore $\frac{1}{N} = \frac{1}{4}$):

$$A = \beta M + (1 - \beta)\frac{1}{N} e \cdot e^T$$

Sostituendo i valori del nostro esercizio otteniamo:

$$A = 0.8 \begin{pmatrix} 1/2 & 0 & 1/3 & 1/2 \\ 1/2 & 0 & 0 & 0 \\ 0 & 0 & 1/3 & 1/2 \\ 0 & 1 & 1/3 & 0 \end{pmatrix} + 0.2 \begin{pmatrix} 1/4 & 1/4 & 1/4 & 1/4 \\ 1/4 & 1/4 & 1/4 & 1/4 \\ 1/4 & 1/4 & 1/4 & 1/4 \\ 1/4 & 1/4 & 1/4 & 1/4 \end{pmatrix}$$

Questa nuova matrice A risulta priva di zeri (grafo completamente connesso, stocastico, aperiodico e irriducibile) e indica che per l'**80% delle volte** ($\beta = 0.8$) il navigatore segue i link uscenti del grafo, mentre per il restante **20% delle volte** ($1 - \beta = 0.2$) effettua un salto casuale (*teleport*) verso uno qualsiasi dei 4 nodi con probabilità uniforme $\frac{1}{4}$.

