Punto 1: Ranking iniziale tramite Similarità del Coseno

Il testo fornisce una matrice con i pesi TF-IDF **non normalizzati** di 5 documenti ($d_1, \ldots, d_5$) rispetto a 6 termini ($t_1, \ldots, t_6$), e una query iniziale $q = (t_1 : 1, t_2 : 2)$, ovvero il vettore $q = (1, 2, 0, 0, 0, 0)$.

Esercizio sul relevance feedback

Sia data la seguente matrice termini documenti contenente ***pesi TF-IDF non normalizzati***:

	t1	t2	t3	t4	t5	t6
d1	0,8	1,2	0	0,7	0	0
d2	0,1	1	1,4	0	0	0
d3	0	0,2	0	0	3,2	0,9
d4	0,1	0,1	0,1	0	2,3	1,7
d5	0	0	2	2	1	0

e la query q=(t1:1, t2:2)

1) Calcolare il ranking dei documenti rispetto alla query *q* utilizzando la similarità del coseno.
2) Assumendo che il *terzo* ed il *quarto* documento del ranking siano rilevanti e che il *primo* documento del ranking non sia invece rilevante, riformulare la query utilizzando l'algoritmo di Rocchio e ricalcolare il ranking dei documenti.

Passo 1.1: Calcolo della lunghezza (norma euclidea) dei vettori

Per calcolare facilmente la similarità del coseno, il primo passo consiste nel **normalizzare i vettori** dividendoli per la propria lunghezza (norma L_2), così da ottenere vettori di lunghezza unitaria. La lunghezza di un vettore si calcola con la radice quadrata della somma dei quadrati dei suoi pesi:

$$|v| = \sqrt{\sum_{i=1}^{n} w_i^2}$$

Applicando la formula ai documenti e alla query si ottiene:

- $|d_1| = \sqrt{0,8^2 + 1,2^2 + 0,7^2} = \sqrt{0,64 + 1,44 + 0,49} = \sqrt{2,57} \approx 1,603$
- $|d_2| = \sqrt{0,1^2 + 1^2 + 1,4^2} = \sqrt{0,01 + 1 + 1,96} = \sqrt{2,97} \approx 1,723$
- $|d_3| = \sqrt{0,2^2 + 3,2^2 + 0,9^2} = \sqrt{0,04 + 10,24 + 0,81} = \sqrt{11,09} \approx 3,330$
- $|d_4| = \sqrt{0,1^2 + 0,1^2 + 0,1^2 + 2,3^2 + 1,7^2} = \sqrt{0,03 + 5,29 + 2,89} = \sqrt{8,21} \approx 2,865$
- $|d_5| = \sqrt{2^2 + 2^2 + 1^2} = \sqrt{4 + 4 + 1} = \sqrt{9} = 3$
- $|q| = \sqrt{1^2 + 2^2} = \sqrt{1 + 4} = \sqrt{5} \approx 2,236$

Passo 1.2: Normalizzazione della matrice

Si divide ciascun peso originale per la norma del rispettivo vettore appena calcolata. Ad esempio:

- Per d_1: $t_1 = \frac{0,8}{1,603} = 0,499$; $t_2 = \frac{1,2}{1,603} = 0,749$; $t_4 = \frac{0,7}{1,603} = 0,437$.
- Per la query q: $t_1 = \frac{1}{2,236} = 0,447$; $t_2 = \frac{2}{2,236} = 0,894$.

Si ottiene così la seconda tabella mostrata a pagina 1, in cui tutti i vettori (documenti e query) sono normalizzati.

Passo 1.3: Calcolo della similarità del coseno e primo Ranking

La formula generale della similarità del coseno tra un documento d e una query q è:

$$\text{cosim}(d, q) = \frac{d \cdot q}{|d| \cdot |q|}$$

Poiché i vettori nella seconda tabella sono **già normalizzati** (hanno lunghezza $|d| = 1$ e $|q| = 1$), la similarità del coseno coincide semplicemente con il **prodotto scalare** (o prodotto interno) tra i vettori normalizzati, ovvero la somma dei prodotti componente per componente:

$$\text{cosim}(d, q) = \sum_{i=1}^{6} w_{d,i} \cdot w_{q,i}$$

Poiché la query q ha valori diversi da zero solo per t_1 $(0,447)$ e t_2 $(0,894)$, basta moltiplicare queste due coordinate:

- $\text{cosim}(d_1, q) = (0,499 \cdot 0,447) + (0,749 \cdot 0,894) = 0,223 + 0,670 = 0,893$
- $\text{cosim}(d_2, q) = (0,058 \cdot 0,447) + (0,580 \cdot 0,894) = 0,026 + 0,519 = 0,545$
- $\text{cosim}(d_3, q) = (0 \cdot 0,447) + (0,060 \cdot 0,894) = 0,054$
- $\text{cosim}(d_4, q) = (0,035 \cdot 0,447) + (0,035 \cdot 0,894) = 0,016 + 0,031 = 0,047$
- $\text{cosim}(d_5, q) = 0$ (non ha né t_1 né t_2)

Ordinando i documenti dal valore più alto al più basso si ottiene il **ranking iniziale**: d_1, d_2, d_3, d_4, d_5.

Punto 2: Riformulazione della query con l'Algoritmo di Rocchio

La traccia ipotizza che l'utente esamini la classifica appena ottenuta (d_1, d_2, d_3, d_4, d_5) e fornisca il seguente feedback:

- **Documenti rilevanti (RL):** il 3° e il 4° documento del ranking, ovvero d_3 **e** d_4.

- **Documenti non rilevanti (NRL):** il 1° documento del ranking, ovvero d_1.

Passo 2.1: Calcolo dei centroidi

Il **centroide** di un insieme di documenti è il vettore medio (la media aritmetica coordinata per coordinata dei vettori normalizzati):

1. **Centroide dei documenti rilevanti (RL):** media tra d_3 e d_4:
   - $t_1 = \frac{0+0{,}035}{2} = 0,0175 \approx 0,017$
   - $t_2 = \frac{0{,}060+0{,}035}{2} = 0,0475 \approx 0,047$
   - $t_3 = \frac{0+0{,}035}{2} = 0,0175 \approx 0,017$
   - $t_4 = \frac{0+0}{2} = 0$
   - $t_5 = \frac{0{,}961+0{,}803}{2} = 0,882$
   - $t_6 = \frac{0{,}270+0{,}593}{2} = 0,4315 \approx 0,432$
2. **Centroide dei documenti non rilevanti (NRL):** essendoci solo d_1, coincide direttamente con il vettore normalizzato di d_1: $(0,499, 0,749, 0, 0,437, 0, 0)$.

Passo 2.2: Applicazione della formula di Rocchio

L'algoritmo di Rocchio sposta il vettore della query originale verso il centroide dei documenti rilevanti e lo allontana da quello dei documenti non rilevanti. La formula applicata nell'esercizio è:

$$q_1 = \alpha \cdot q_0 + \beta \cdot RL - \gamma \cdot NRL$$

Con i parametri scelti nell'esercizio ($\alpha = 1$, $\beta = 0,75$, $\gamma = 0,25$) diventa:

$$q_1 = q_0 + 0,75 \cdot RL - 0,25 \cdot NRL$$

Vediamo il calcolo componente per componente mostrato nella tabella di pagina 2:

- t_1: $0,447 + 0,75(0,017) - 0,25(0,499) = 0,447 + 0,01275 - 0,12475 = 0,335 \approx 0,336$
- t_2: $0,894 + 0,75(0,047) - 0,25(0,749) = 0,894 + 0,03525 - 0,18725 = 0,742 \approx 0,743$
- t_3: $0 + 0,75(0,017) - 0,25(0) = 0,01275 \approx 0,013$
- t_4: $0 + 0,75(0) - 0,25(0,437) = -0,109$
- t_5: $0 + 0,75(0,882) - 0,25(0) = 0,6615 \approx 0,661$
- t_6: $0 + 0,75(0,432) - 0,25(0) = 0,324$

Regola sui pesi negativi (*): Nel modello vettoriale con Rocchio, i pesi negativi non hanno significato per rappresentare l'importanza di un termine in una query, pertanto vengono posti a 0. Il valore $-0,109$ di t_4 viene quindi azzerato.

La nuova query q_1 ha quindi la seguente forma:

$$q_1 = (0,336, 0,743, 0,013, 0, 0, 661, 0,324)$$

(Nota teorica: come si vede, la query si è arricchita dei termini t_5 e t_6 che non erano presenti nella ricerca iniziale dell'utente ma che caratterizzano fortemente i documenti d_3 e d_4 giudicati rilevanti.)

Passo 2.3: Ricalcolo della similarità e nuovo Ranking

Infine, a pagina 3 viene ricalcolato il prodotto scalare tra ciascun documento normalizzato e la nuova query q_1:

- $\text{cosim}(d_1, q_1) = (0,499 \cdot 0,336) + (0,749 \cdot 0,743) + (0,437 \cdot 0) = 0,168 + 0,557 = 0,725$ *(Nota: nel PDF è riportato $0,675$, probabilmente perché chi ha svolto l'esercizio ha normalizzato anche q_1 prima del prodotto oppure ha tenuto conto di arrotondamenti intermedi, ma l'ordine del ranking finale non cambia)*.
- $\text{cosim}(d_3, q_1) = (0,060 \cdot 0,743) + (0,961 \cdot 0,661) + (0,270 \cdot 0,324) = 0,045 + 0,635 + 0,087 = 0,767$
- $\text{cosim}(d_4, q_1) = (0,035 \cdot 0,336) + (0,035 \cdot 0,743) + (0,035 \cdot 0,013) + (0,803 \cdot 0,661) + (0,593 \cdot 0,324) = 0,761$

(Nota sul valore di $\text{cosim}(d_1, q_1) = 0,675$ nel PDF: quel numero esatto si ottiene se nel prodotto scalare con d_1 non si azzera il peso negativo $-0,109$ di t_4: infatti $0,724 - (0,437 \cdot 0,109) = 0,676 \approx 0,675$. È una piccola svista di calcolo nel foglio del professore per il solo d_1, dato che nella riga precedente aveva dichiarato di aver azzerato t_4).

Ordinando i nuovi punteggi ottenuti ($d_3 = 0,767$, $d_4 = 0,761$, $d_1 = 0,675$, $d_2 = 0,461$, $d_5 = 0,156$), la **nuova classifica finale** diventa: d_3, d_4, d_1, d_2, d_5

L'algoritmo ha raggiunto il suo scopo: d_3 e d_4 (giudicati rilevanti) sono saliti al 1° e 2° posto, mentre d_1 (giudicato non rilevante) è stato penalizzato scendendo dal 1° al 3° posto.